

Análise de Dados com Python [T1]

Mini-Projeto Avaliativo - Módulo 1 - Semana 07

SUMÁRIO

1. CONTEXTUALIZAÇÃO	1
2. DESAFIO	1
3. RESULTADOS ESPERADOS (ENTREGA)	2
4. REQUISITOS DAS TAREFAS	2
5. CRITÉRIOS DE AVALIAÇÃO	3

1. CONTEXTUALIZAÇÃO

Você está desenvolvendo uma Análise Exploratória de Dados (AED) aplicada ao varejo para aprender como transformar dados brutos em informações úteis.

A base “Varejo” contém registros reais de compras (datas, clientes, produtos, categorias e valores). Aprender a verificar qualidade, limpar e sumarizar esses dados é uma habilidade prática essencial para quem trabalha com BI e Visualização de Dados.

Neste mini-projeto você vai praticar tarefas comuns no trabalho: identificar problemas nos dados (valores nulos, tipos incorretos, duplicados), tratar esses problemas com ferramentas como pandas e gerar estatísticas simples e funções de agrupamento, para responder perguntas operacionais (quem compra mais, quais categorias vendem mais, como variam as vendas ao longo do tempo).

O objetivo educacional é que, ao final, você saiba preparar uma base para análises mais avançadas ou para alimentar um dashboard: entender os dados, limpá-los, extrair estatísticas descritivas e comunicar os principais insights de forma objetiva.

2. DESAFIO

Entregar um script em Python que realize uma **Análise Exploratória** da base Varejo seguindo etapas claras, documentadas e reproduzíveis.

Etapas obrigatórias:

- Carregar a base Varejo.csv com pandas e mostrar: número de registros, colunas e tipos de dados.
- Verificar e reportar ao menos dois problemas básicos: valores nulos por coluna, duplicatas e possíveis inconsistências (ex.: datas inválidas ou categorias vazias).
- Fazer as três etapas de limpeza mínima necessária: remover ou imputar nulos (explique a escolha), eliminar duplicatas relevantes e ajustar tipos de dados (ex.: converter coluna DATA para datetime).
- Gerar estatísticas descritivas básicas para coluna de número de filhos do cliente (média; mediana; desvio padrão; moda; máximo; mínimo; e contagem, quartis)

- Explorar padrões de agrupamento **com pelo menos dois agrupamentos** (por exemplo: gênero com mais vendas, compras), usando `groupby()` ou `pivot_table()`.
- Produzir um pequeno bloco de conclusões **(3–6 tópicos)** com os principais **insights** obtidos e possíveis problemas remanescentes na base. Notebook Python, MD ou um “print”.

Requisitos técnicos mínimos:

- O script deve ser executável em VsCode ou Google Colab (arquivo .py).
- Usar pandas; outras bibliotecas são opcionais (NumPy, Matplotlib, Seaborn).

Base de dados (varejo) sugerida no Kaggle:

<https://www.kaggle.com/datasets/namespaiva/base-varejo/data>

3. RESULTADOS ESPERADOS (ENTREGA)

Para que sua avaliação seja concluída com sucesso, você deve entregar:

1. **Código-Fonte (Python):** Um arquivo `.py` ou link do **Google Colab** contendo a lógica desenvolvida. O código deve estar comentado, explicando o que cada bloco de lógica realiza.
2. **Repositório no GitHub:** O projeto deve ser enviado para um repositório público no seu GitHub. Espera-se que:
 - O repositório tenha um arquivo `README.md` básico explicando o projeto.
 - O histórico de *commits* demonstre o progresso do trabalho (não envie tudo em um único commit final!).
3. Arquivo `README_NomeDoAluno_Turma.md`, com instruções simples (ex.: "Abra no VsCode ou Colab e rode todas as células" ou "python Miniprojeto_...py").
4. Os arquivos com a solução do mini-projeto deverão ser inseridos no **Repositório GitHub em modo público** (repositório de sua conta pessoal do GitHub). Padrão de nome do Github `Miniprojeto_NomeAluno_Turma`. (Turma:Análise_de_Dados_T1)
5. O **link do Repositório GitHub** deverá ser submetido na tarefa **Módulo 1 - Mini-Projeto Avaliativo**, presente na semana 07 do AVA até o dia **01/06/2026 às 12h..cv**

4. REQUISITOS DAS TAREFAS

Neste item devem ser listadas tarefas em formato de Sprint para que os estudantes possam realizar durante o período de execução do Mini-projeto Avaliativo. Seguindo as orientações e critérios disponibilizados neste arquivo.

- **Sprint 1 (Importação dos dados):** Realização da importação dos dados na plataforma Kaggle para a IDE VsCode ou Colab, onde o script será executado.
- **Sprint 2 (Transformação de Strings, Integer e Float e Datetime):** Desenvolvimento das funções de limpeza de texto, inteiros e decimais usando métodos e expressões regulares.
- **Sprint 3 (Limpeza de Nulos e Duplicatas):** Aplicação das condicionais e funções para identificação e substituição de valores vazios e de str para valores de data tipo datetime, na tabela de varejo.

- **Sprint 4 (Estatística Descritiva):** Aplicação das funções estatísticas para coletar parâmetros da coluna de Número de filhos do cliente.
- **Sprint 5 (Relatório e Documentação):** Construção dos contadores do relatório final exibido no terminal, finalização do [README.md](#) com a reflexão teórica e submissão do link no AVA.
- **Sprint 6 (Versionamento):** Envio dos arquivos (script + [README.md](#) + df_limpo), via Git para o repositório no GitHub.

5. CRITÉRIOS DE AVALIAÇÃO

A tabela abaixo apresenta os critérios que serão avaliados durante a correção do projeto. O mesmo possui variação de nota de 0 (zero) a 10 (dez) como nota mínima e máxima, e possui peso de **25% sobre a avaliação do módulo**.

Serão desconsiderados e atribuída a nota 0 (zero) os projetos que apresentarem plágio de soluções encontradas na internet ou de outros colegas. Lembre-se: Você está livre para utilizar outras soluções como base, mas não é permitida a cópia.

Documentação do Projeto (2,50)			
Nº	Critério de Avaliação	0	1,25
1	Versionamento	Não entregou o repositório no GitHub contendo os arquivos organizados e um README.md explicativo com a reflexão teórica obrigatória sobre ETL e qualidade de dados.	Entregou o repositório no GitHub contendo os arquivos organizados e um README.md explicativo com a reflexão teórica obrigatória sobre ETL e qualidade de dados.
2	Documentação	Não desenvolveu Arquivo README.md contendo de 3-6 tópicos com insights obtidos da análise dos dados.	Desenvolveu Arquivo README.md contendo de 3-6 tópicos com insights obtidos da análise dos dados.

Desenvolvimento do Projeto (7,50)				
Nº	Critério de Avaliação	0	0,75	1,50
3	Manipulação de Arquivos CSV	Não realizou a leitura e extração dos arquivos de dados de forma parcialmente estruturada (csv.DictReader).	Realizou a leitura e extração dos arquivos de dados de forma parcialmente estruturada (csv.DictReader).	Realizou a leitura e extração dos arquivos de dados de forma estruturada e nativa (csv.DictReader).

4	Tratamento de Nulos e Condicionais	Não implementou a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e não tratou os nulos das dimensões físicas, justificando a escolha.	Implementou parcialmente a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e tratou parcialmente os nulos das dimensões físicas, justificando a escolha.	Implementou a lógica (if/else) para preencher categorias vazias com "Sem Categoria" e tratou corretamente os nulos das dimensões físicas, justificando a escolha.
5	Regras de Negócio e Datas	Não validou a regra do identificador de número de compra separando os registros, e converteu parcialmente a string de data da compra utilizando o módulo datetime.	Validou parcialmente a regra do identificador de número de compra separando os registros, e converteu parcialmente a string de data da compra utilizando o módulo datetime.	Validou a regra do identificador de número de compra, e converteu com sucesso a string de data da compra utilizando o módulo datetime.
6	Padrões de Agrupamento	Não explorou padrões de agrupamento com pelo menos duas combinações.	Explorou parcialmente padrões de agrupamento com uma combinação.	Explorou padrões de agrupamento com pelo menos duas combinações.
7	Geração de Estatísticas Básicas	Não gerou as estatísticas básicas de acordo com a coluna Número de filhos dos clientes , não contemplando os parâmetros elencados	Gerou parcialmente as estatísticas básicas de acordo com a coluna Número de filhos dos clientes , contemplando parte dos parâmetros elencados	Gerou as estatísticas básicas de acordo com a coluna Número de filhos dos clientes , contemplando todos os parâmetros elencados